UNIVERSITÀ
DEGLI STUDI
DI BERGAMO

Analisi dropout universitario

Dalla previsione del rischio alla decisione: modelli di early e mid drop-out prediction per il progetto SPEED

Meregalli Marta
Peraro Francesco
Savaresi Dario
Voschion Claudia

Master AIDA Bicocca

23-10-2026

Introduzione | Università italiana

Le università statali sono **enti pubblici autonomi:** regole e fondi arrivano dal MUR.
UniBG ha circa **4.500 matricole** l'anno nei corsi di laurea triennali.



Immatricolato e iscritto

Immatricolato: iscritto al primo anno.
Iscritto: iscritto al corso universitario.



Coorte

Riunisce le matricole di uno stesso anno accademico.



Fuori corso

Chi non si laurea entro l'ultima sessione di laurea disponibile del ciclo di studi.

Introduzione | Finanziamenti ateneo

Due entrate principali, il **FFO** del MUR e le **tasse**: dipendono da quanti studenti si iscrivono e restano.

FFO

- 9.4 miliardi di euro all'anno per tutte le università.

Componente	Come viene divisa	Legame con studenti
Quota base	38% dell'FFO 2026, in base al costo standard per studente	Diretto: conta gli studenti regolari
Quota premiale	Ricerca (VQR), reclutamento, indicatori dell'ateneo	Indiretto: alcuni indicatori, se scelti dagli atenei, misurano la regolarità
Quota perequativa	Attutisce le variazioni da un anno all'altro	Nessuno: fa da cuscinetto

Contribuzione studentesca

- Proporzionali all'ISEE, con fascia esente (no-tax Area).
- Chi abbandona smette di versare.
- Chi è fuori corso continua a versare, spesso con maggiorazione.

Ogni abbandono fa perdere anni di finanziamento e riduce la quota dell'ateneo.

Introduzione | Dropout

13,3%
abbandona tra I e II anno negli atenei statali

18,8%
abbandona tra I e II anno nelle telematiche

62,7%
si laurea entro 6 anni dall'iscrizione alla triennale

15%
cambia corso o ateneo entro un anno

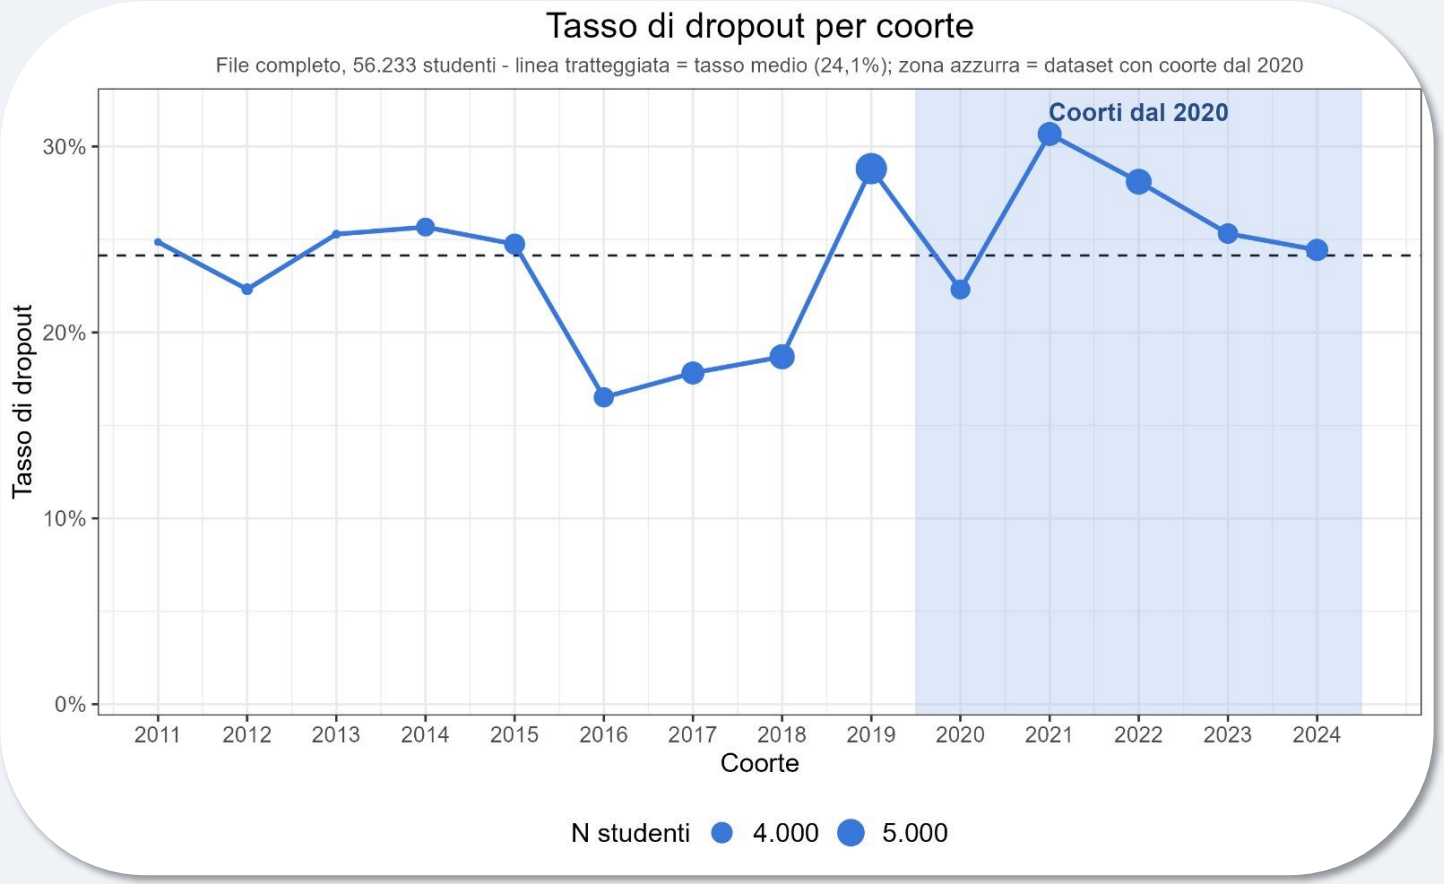
Due forme di abbandono

- **Esplicito:** lo studente esce dal sistema, rinunciando o non rinnovando l'iscrizione.
- **Implicito:** resta iscritto ma non fa più né esami né altri eventi di carriera.

Perché è problema

- **Studente:** tempo e denaro spesi senza un titolo.
- **Territorio:** a Bergamo è laureato il 21,8% dei 25-39enni (Italia 28,1%).
- **Ateneo:** meno FFO e tasse.

Introduzione | Dropout UniBG



Introduzione | Cosa esiste già e cosa aggiungiamo

Il dropout è un tema rilevante, e per questo ci sono già studi che stimano **modelli di previsione** per contrastare la dispersione universitaria.

Previsione del dropout

Cannistrà et al. (2022), con Agasisti: previsione precoce del dropout. Politecnico riduce il drop-out del 50%.

Previsione e servizi

Li, Origo et al. (2026): la previsione collegata ai servizi di supporto. È l'impianto che usa UniBG.

→ Nel 2025/26 UniBG ha contattato **1300** matricole e ha attivato una serie di servizi: **SPEED**.

Cosa facciamo noi

Modello di previsione
stima la probabilità di abbandono p

+

Matrice di pay-off
costi c, efficacia e, valore V di uno studente trattenuto

→

Soglia di attivazione t*
ricalcolata sul profitto: 0,31, non 0,5

Dati | Dati di partenza e popolazione

Dataset di partenza

- **carriere** (283.680 records): un record per iscrizione, con corso, coorte, anagrafica, residenza, maturità, ISEE e ISPE.
- **ad_superate** (1.832.095 records): gli esami (attività didattiche) con data, voto, CFU ed esito.
- **iscritti** (308.314 records): le iscrizioni anno per anno, con la borsa di studio.
- **tolc_completo** (106.966 records): punteggi dei test TOLC, una riga per sezione.

↓

Otteniamo un dataset di **56.233 matricole** tenendo solo le iscrizioni triennali, con coorte dal 2011 fino al 2024 e anno di iscrizione che corrisponde a coorte. Di queste, **13.575** non si sono iscritte al secondo anno (24,1%).

Variabile target: dropout ricavato da 'iscritti' (1 abbandona, 0 continua)

Dati | Costruzione delle variabili

Anagrafica e provenienza: genere, cittadinanza, area di residenza (Lombardia, altra regione, estero). Tempo in auto verso Bergamo (OSRM) e FUORI_SEDE_FLG (residenza estera, oltre 90 minuti o comune senza tempo calcolabile).

Economia: ISEE in classi (bassa fino a 28.000 euro, media fino a 58.000, alta oltre 58.000, senza ISEE), ISPE in log e borsa di studio.

Maturità e iscrizione: voto in percentuale, tipo di maturità in 9 gruppi, anni dalla maturità in 5 classi, periodo di iscrizione (entro ago, set-2 ott, entro il 13 nov, oltre).

OFA (Obblighi Formativi Aggiuntivi): OFA_OBBLIGO: variabile che indica se, al momento dell'immatricolazione, lo studente aveva l'obbligo di assolvere l'OFA.

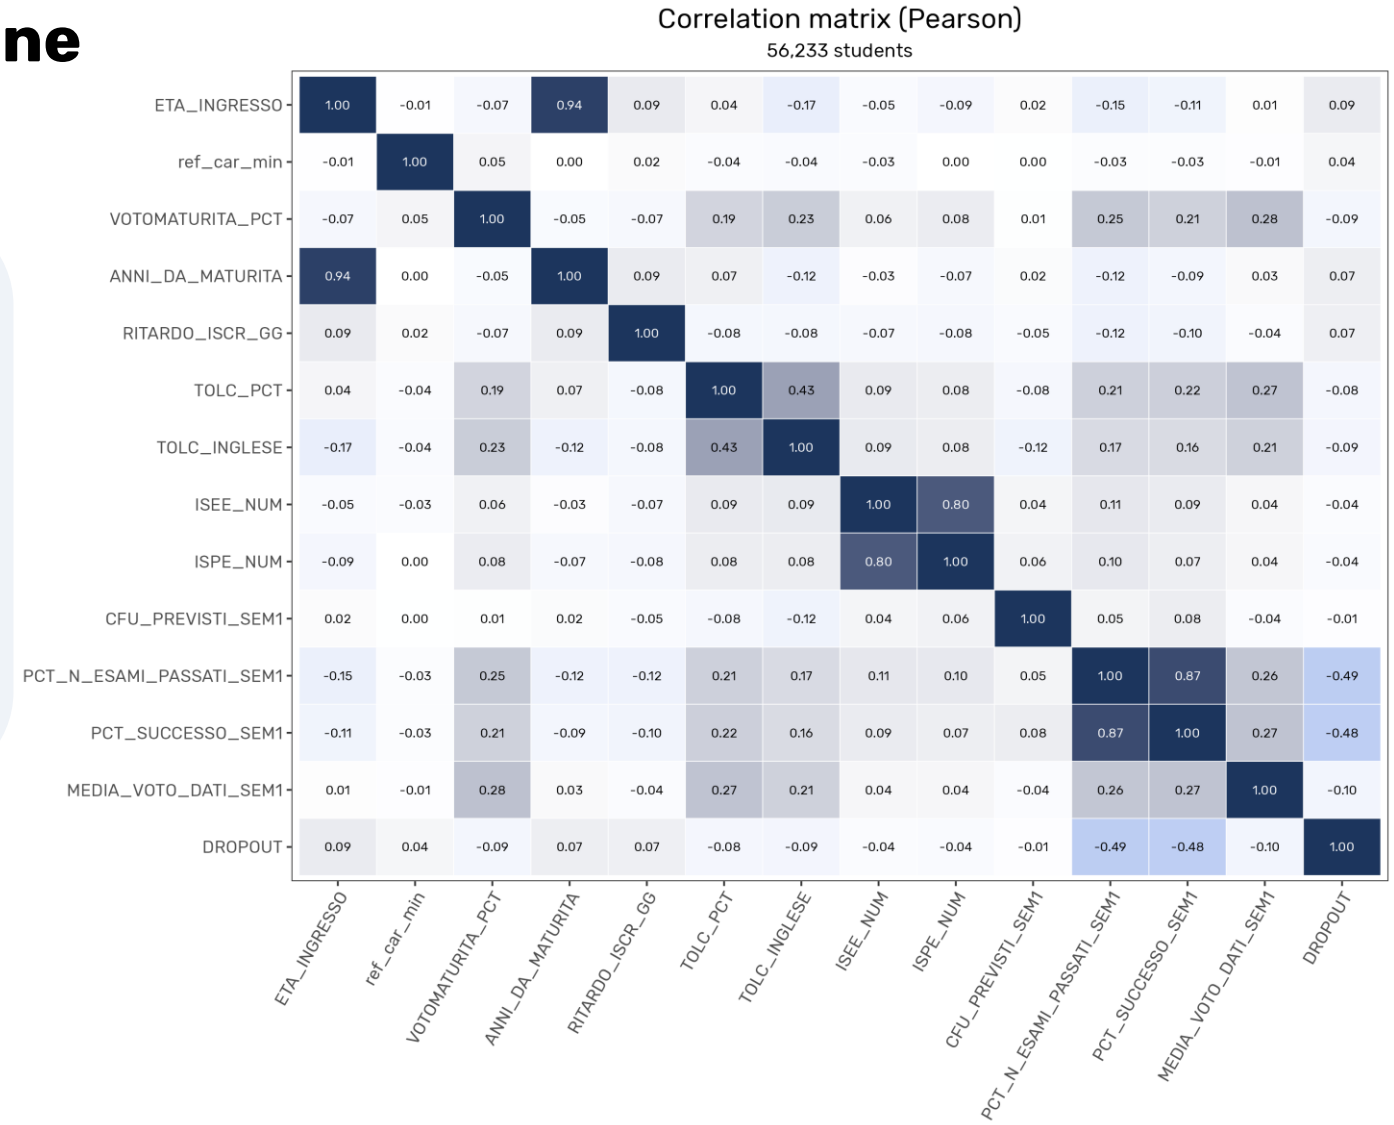
TOLC: punteggio in percentuale con inglese a parte, percentile nel proprio corso e TOLC_STATO (nessun TOLC, senza inglese, con inglese).

Carriera per semestre: esami contati per semestre (ott-feb e mar-set), senza doppioni e senza esami OFA.
Per semestre: % esami passati sul previsto, % successo, media voti e stato_sem in quattro gruppi.

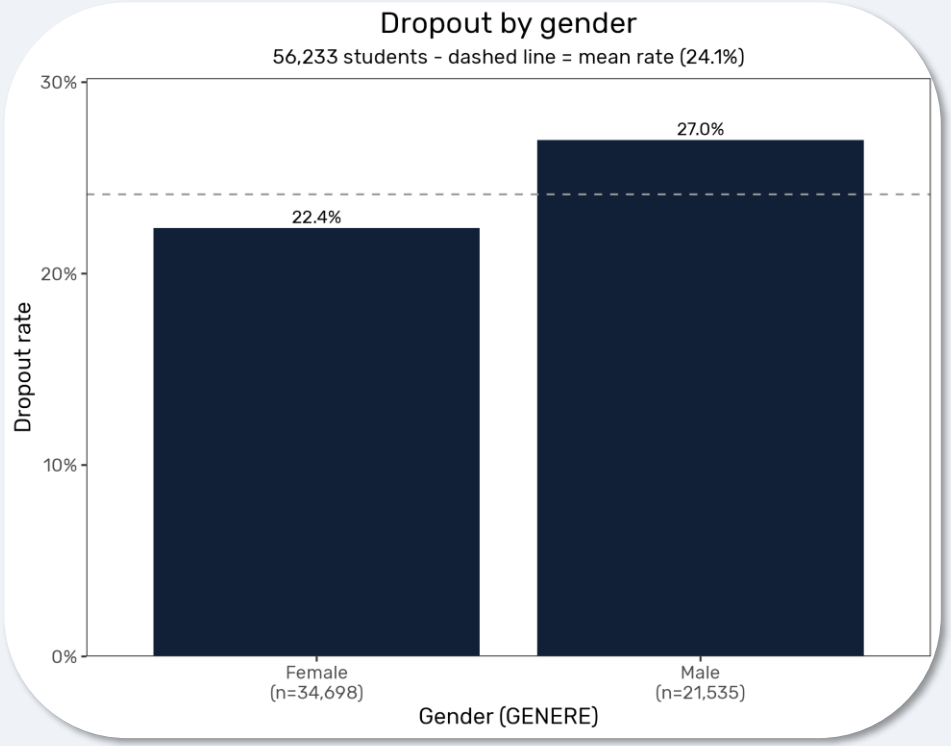
Dati | Matrice di correlazione

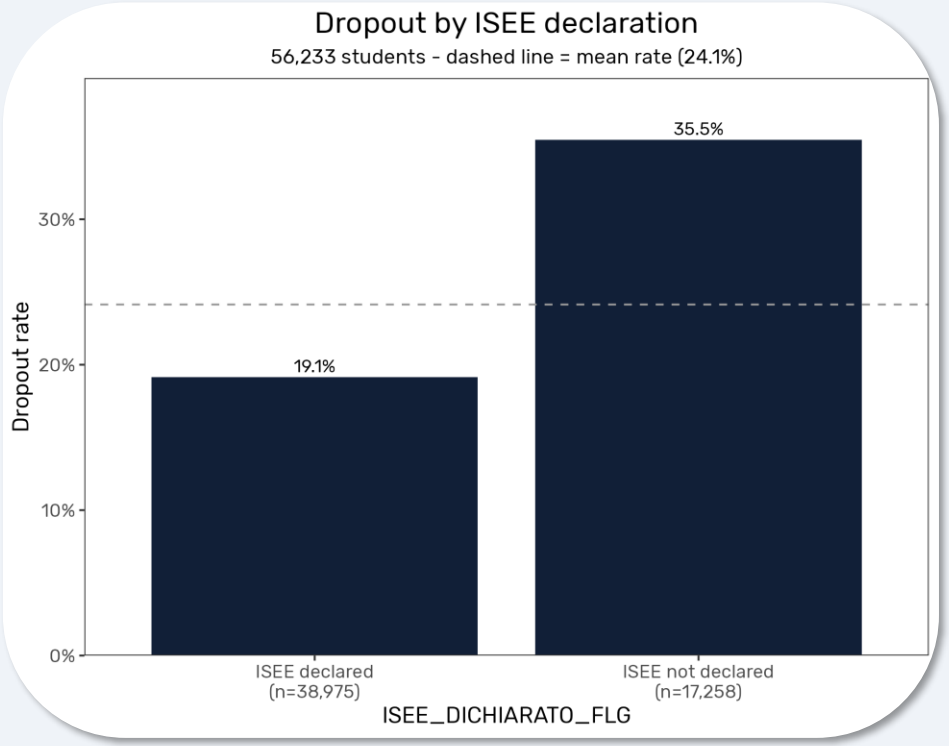
Punti salienti:

- Anni da maturità – età ingresso.
- ISEE – ISPE.
- % esami passati – % successo sem1.
- Dropout legato soprattutto al rendimento sem1.
- Variabili note prima dell'inizio del sem1 hanno correlazioni deboli con dropout.

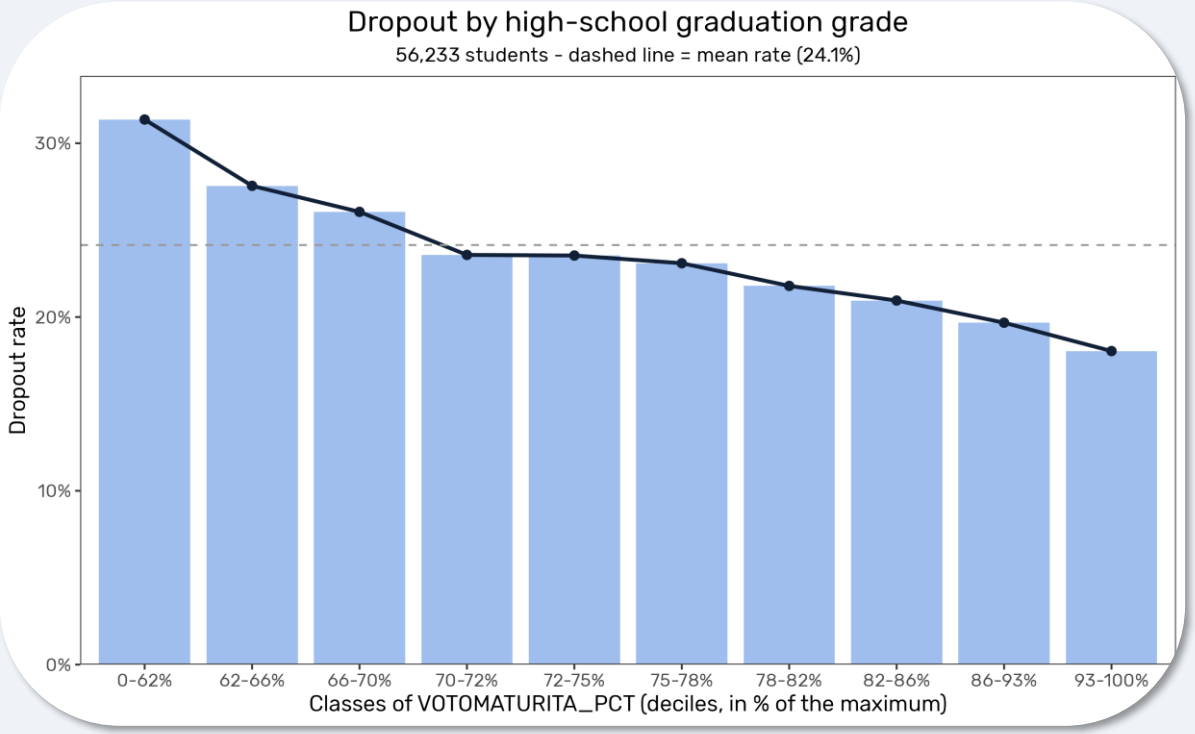


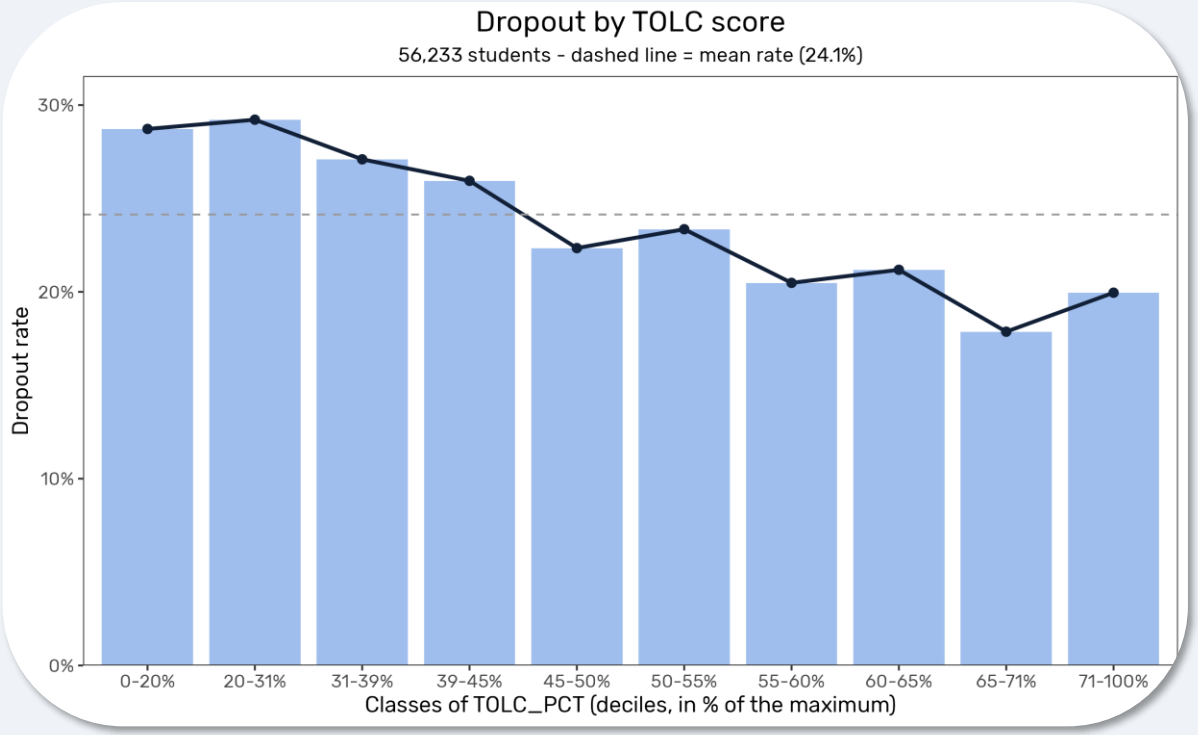
Analisi descrittiva | Dropout



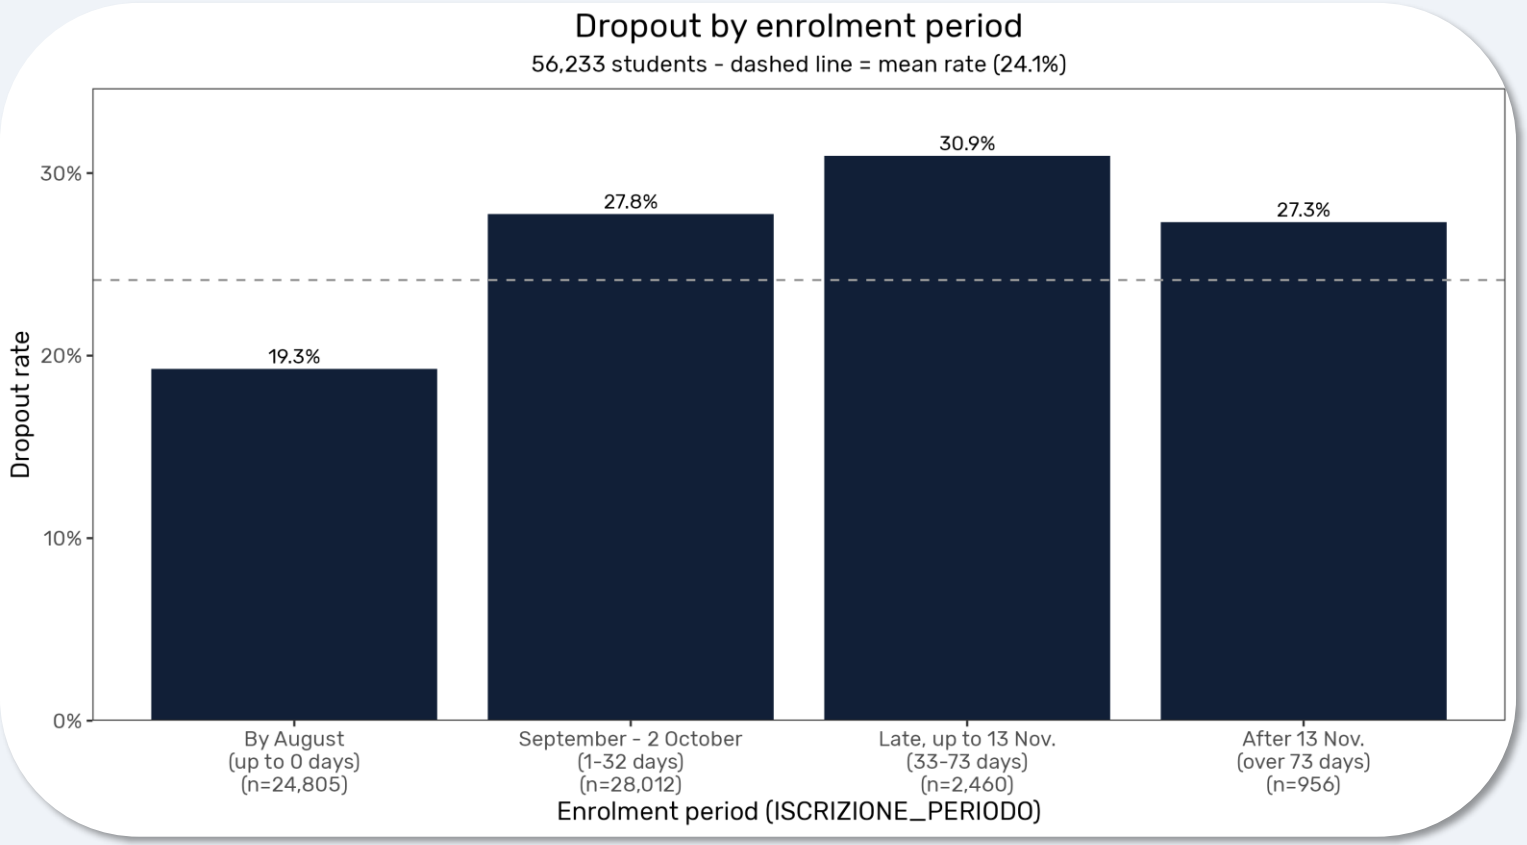


Analisi descrittiva | Dropout

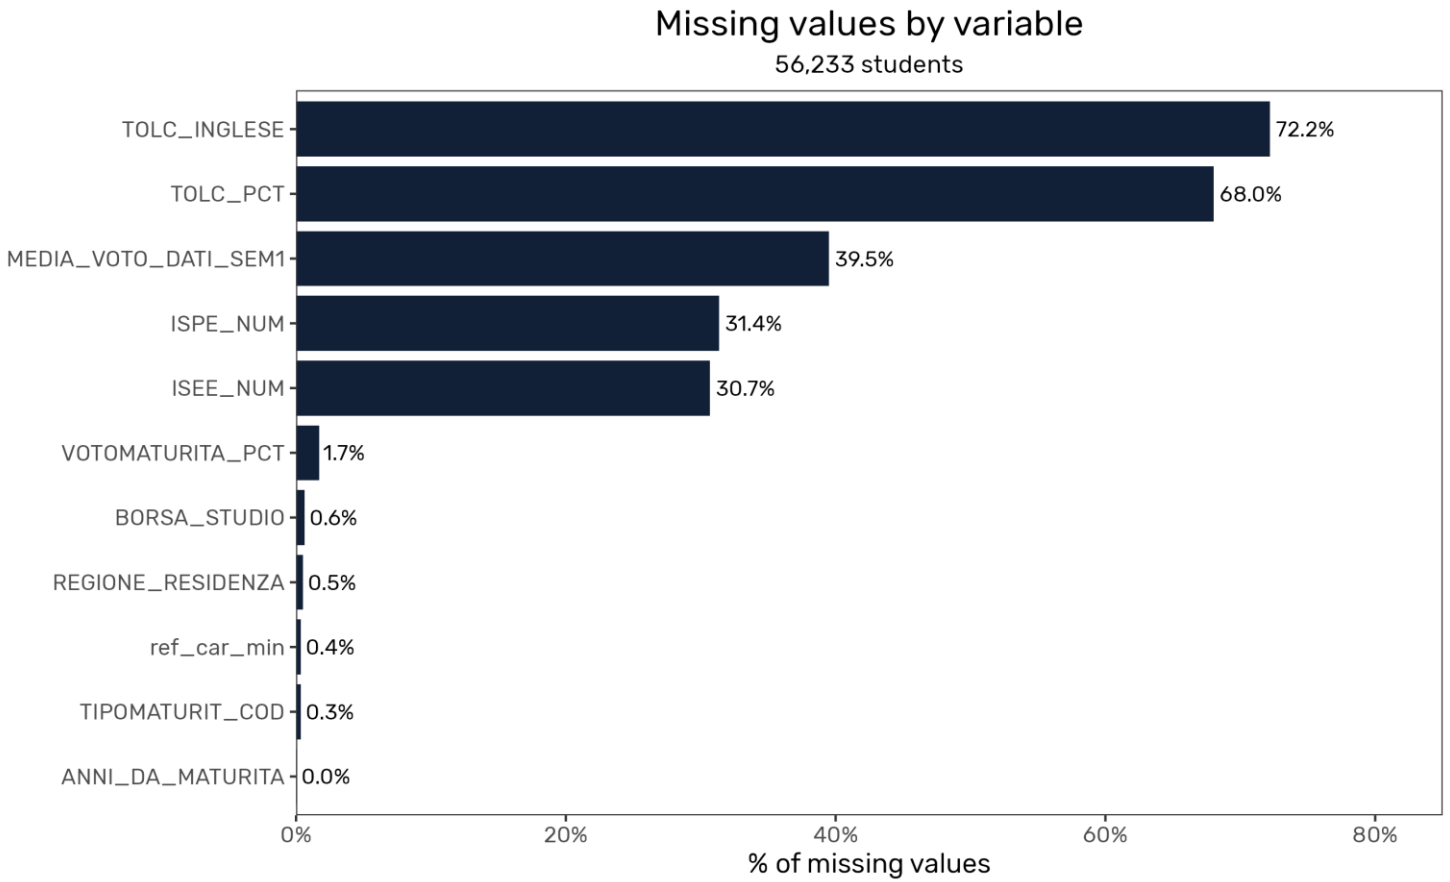




Analisi descrittiva | Dropout



Dati | Gestione Na



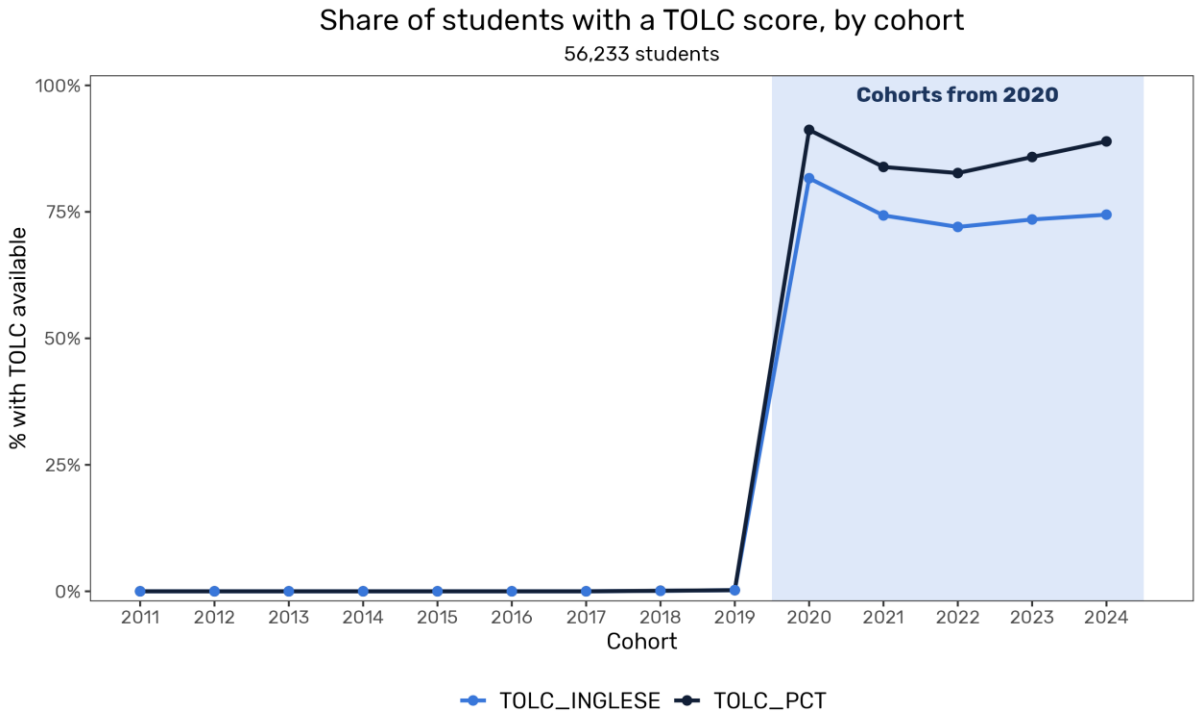
Cosa indica:
Molti NA non sono dati persi:

- Il TOLC esiste solo dal 2020.
- La media voto manca senza esami.
- L'ISEE manca se non è stato dichiarato.

Come li gestiamo:

- TOLC: solo coorti dal 2020, con indicatore TOLC_STATO.
- Media voto: posta a 0, più lo stato del 1° semestre in 4 gruppi.
- ISEE: in 4 fasce.
- Altre variabili: NA come categoria (ESTERO, MANCANTE, No).

Dati | Divisione dataset



SPLIT

70% train
20% validation
10% test

	Data Set	
	Train / Validation / Test	Contenuto
A	39.364 / 11.246 / 5.623	tutte le coorti, senza TOLC
B	14.541 / 4.144 / 2.132	dal 2020, TOLC imputato

Dati | Scenari

Scenario	Quando	Variabili	Informazioni
Early	Ottobre, all'immatricolazione	18	Anagrafica, residenza, maturità, TOLC, OFA, ISEE e ISPE
Mid	Dopo il primo semestre	25	Le stesse + primo semestre e borsa

Perché B?

- Contiene le variabili del **TOLC** (le poche mancanti sono imputate con bagImpute).
- Il TOLC è tra le poche **informazioni disponibili a ottobre**, quando non ci sono ancora esami: per questo migliora la previsione dell'early dropout.
- Per noi **l'obiettivo è migliorare Early** per prevenire il dropout tempestivamente.
- Il campione è più piccolo (coorti dal 2020: 20.871 studenti contro 56.233 del dataset A), ma i risultati sono migliori.
- Lo usiamo anche per il mid dropout, per avere gli **stessi dati in entrambi i modelli.** Qui conta soprattutto il primo semestre, quindi con A i risultati sarebbero simili.

Classificatori | Sei classi testate

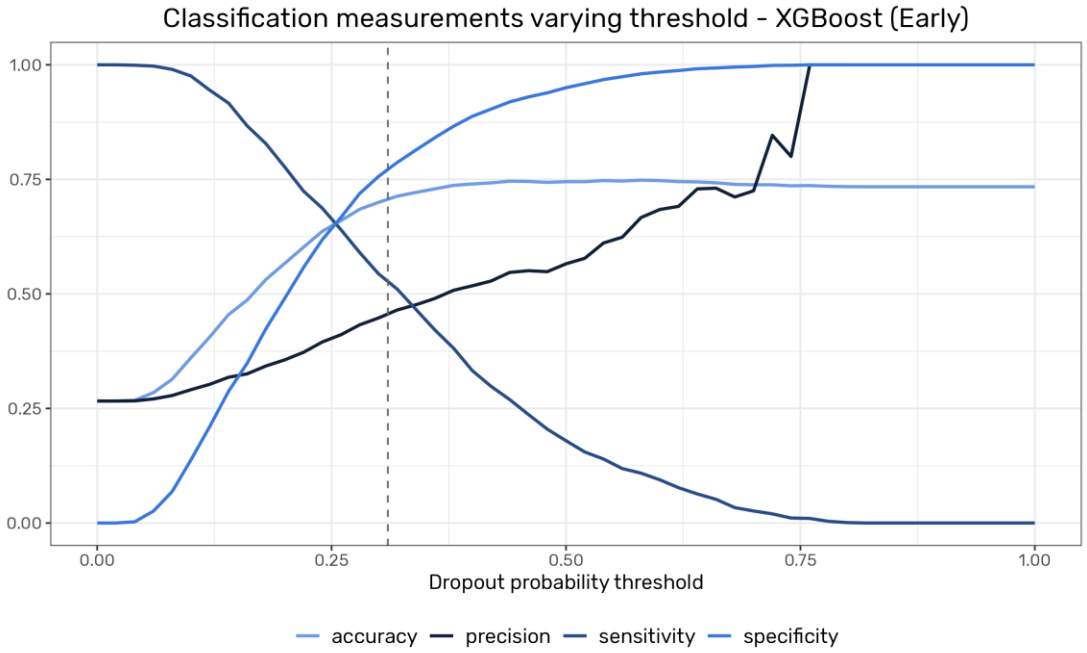
1. **Naive Bayes**
2. **Logistic Regression**
3. **k- Nearest Neighbors**
   - Distanza euclidea
   - Distanza Gower
   - Distanza Gower pesata
4. **Reti Neurali**
5. **Random Forest**
6. **XGBoost**

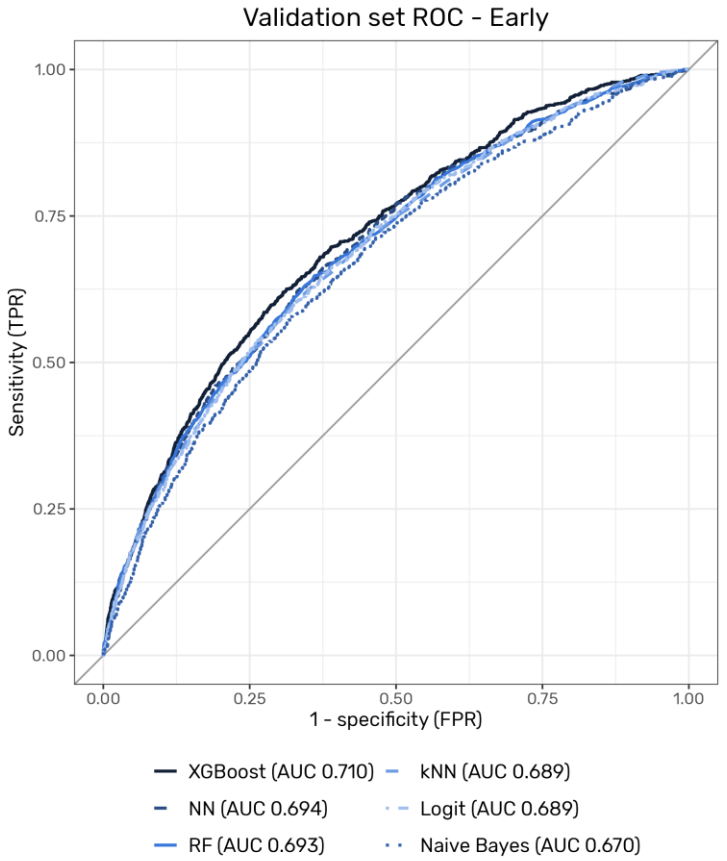
Considerando gli iper parametri dei modelli, sono stati addestrati **270 classificatori diversi**

Classificatori | Pre-processing dei dati

Model	Categoriche	Numeriche	NZV	Correlazione
Naive Bayes	Top-10 livelli	Discretizzazione per decili	No	|Spearman| > 0,9 elimina
Logit	Nessun trattamento	Nessun trattamento	No	No
NN	Nessun trattamento	Standardizzate	No	No
kNN	Top-10 livelli	Euclidea: standardizzate, Gower: tagliate ai 1 e 99 percentili	Si	|Pearson| > 0,9 elimina
RF	Top-20 livelli	Nessun trattamento	No	No
XGBoost	Dummy per ogni livello	Nessun trattamento	No	No

Modelli a confronto | Scenario early

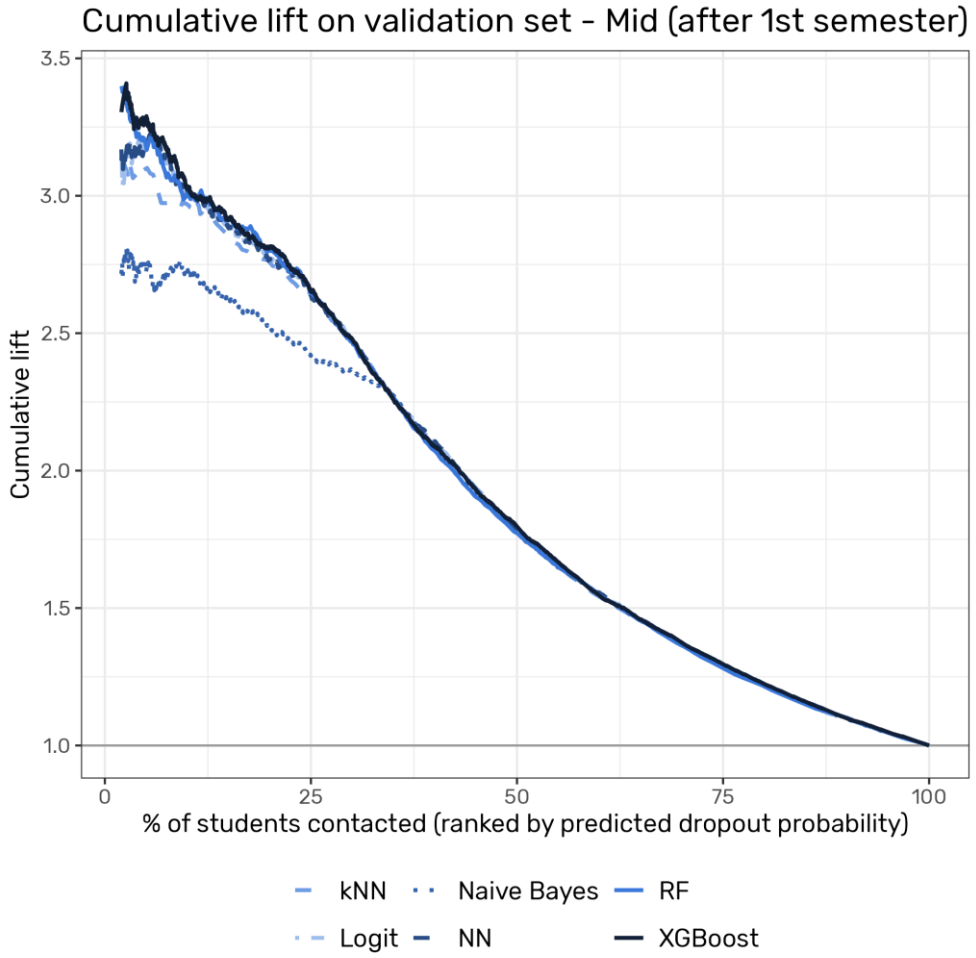




Nello scenario **Early,** la curva ROC del classificatore XGBoost ha **AUC maggiore** ed è sempre al di sopra di quelle di tutti gli altri classificatori.

↪ In questo scenario **XGBoost è il classificatore migliore**.

Modelli a confronto | Scenario Mid

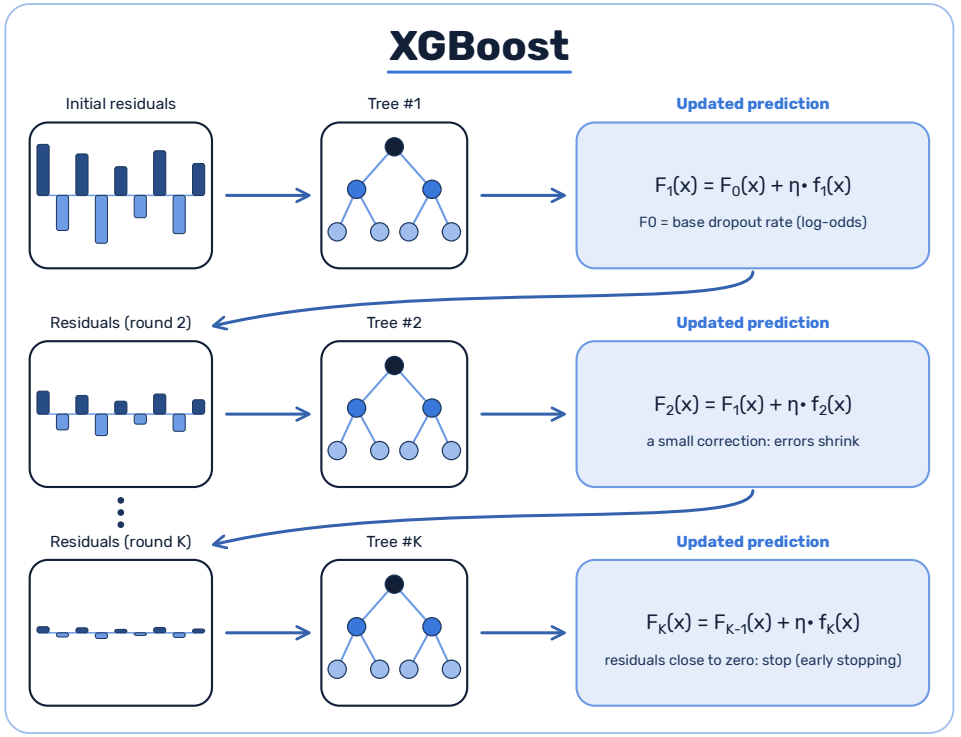


- Nello scenario Mid, le **curve ROC** di quasi tutti i classificatori si **sovrappongono**.
- Le **curve lift** mostrano una sostanziale **equivalenza** di tutti i classificatori, ad eccezione di **Naive Bayes**, sintomo del fatto che l'informazione sui dropout può essere estratta in modo simile da tutte le tecniche esplorate.
- In generale, **XGBoost** può essere considerato il **modello migliore** potendo contattare un numero esiguo di studenti: in questo caso, la proporzione di *dropout* identificati è più di tre volte quella che si otterrebbe da un campione casuale.

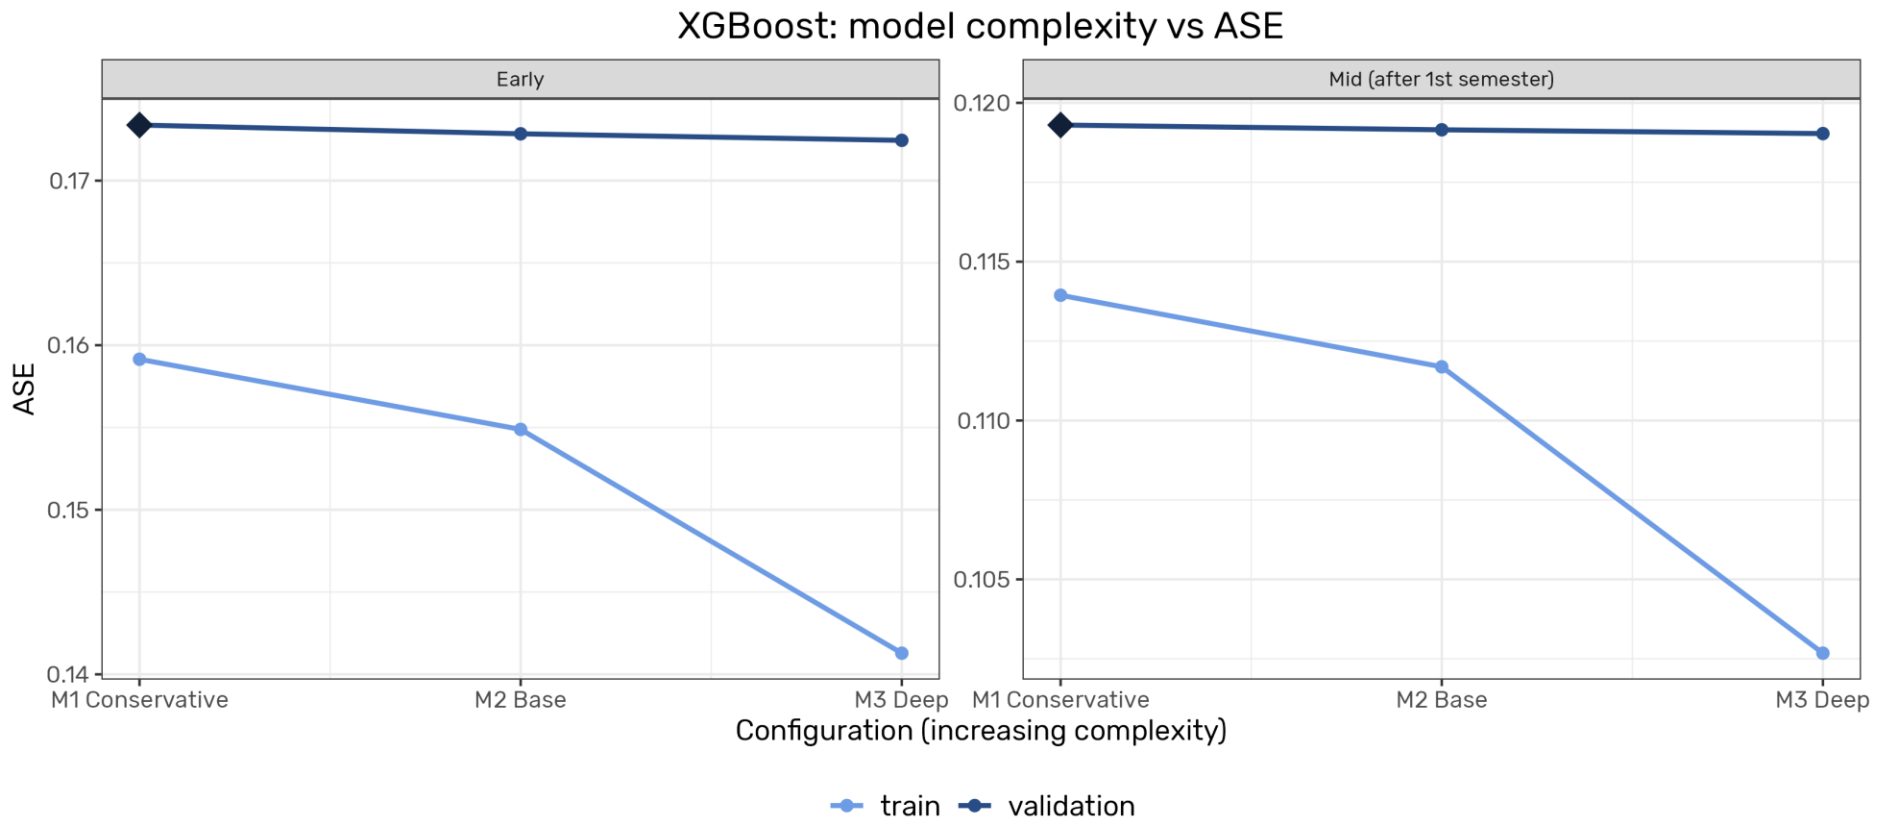
XGBoost | Idea e iperparametri

- **Boosting:** alberi piccoli, addestrati in sequenza con l'obiettivo di correggere gli errori di classificazione degli alberi precedenti.
- La **complessità** di ciascun albero è **ridotta** per evitare l'overfitting (a differenza di altri metodi *ensemble* come Random Forest, XGBoost può specializzarsi troppo sui dati di training).

Tre classificatori testati per ciascuno scenario, con complessità crescente:			
	M1	M2	M3
η (learning rate)	0,03	0,05	0,05
Max_depth	3	4	6
Min_child	10	5	3
L2 regularization	5	1	1



XGBoost | Scelta del modello

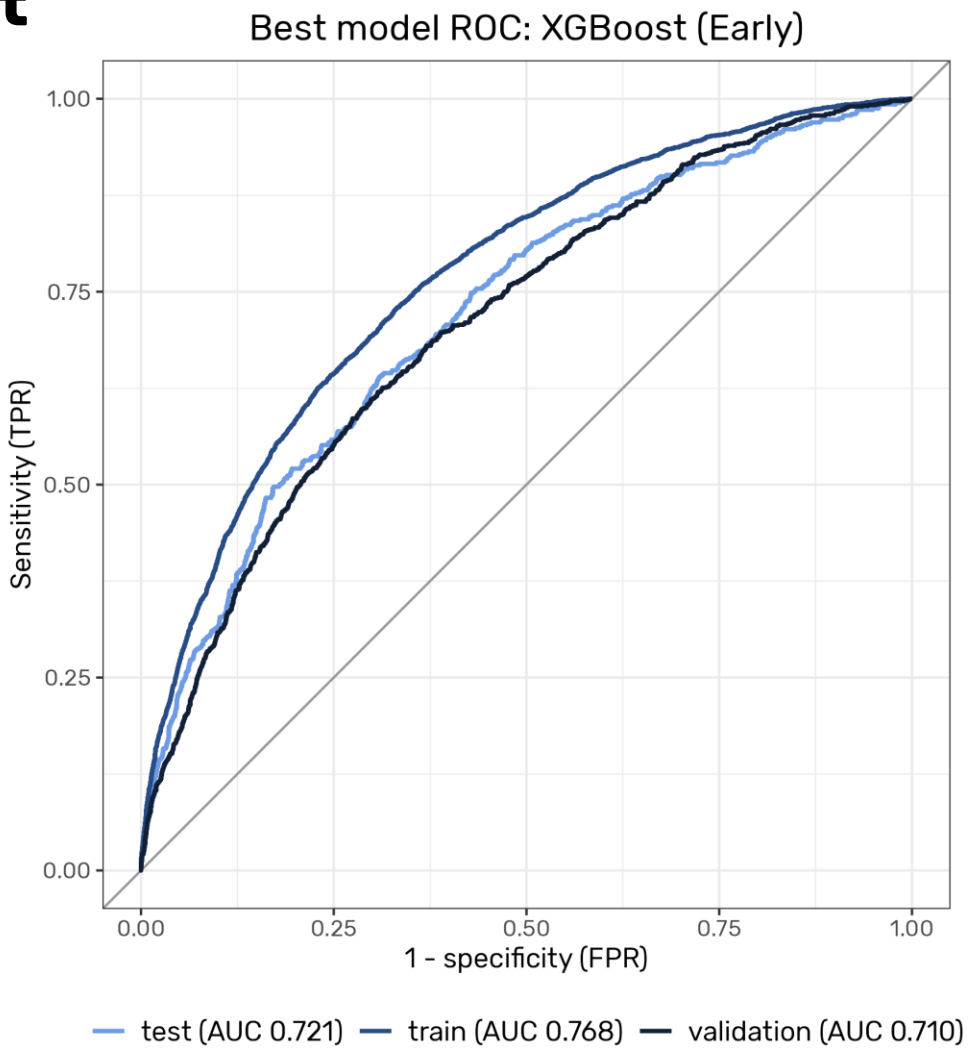


ASE validation è praticamente **piatto** per tutti i modelli, mentre **ASE training** continua a **decrescere** perché overfitta i dati: si sceglie il modello più semplice.

XGBoost | Performance sul test set

- Il comportamento del classificatore selezionato è **coerente con il comportamento atteso**: su test e validation set, le performance si equivalgono.
- Nello **scenario Early** è possibile identificare circa il **15% dei *dropout* con un FPR < 5%**.

	ASE Val	ASE Test	AUC Val	AUC Test
Early	0,173	0,168	0,710	0,721
Mid	0,119	0,126	0,872	0,857



Pay-Off | Quanto vale uno studente trattenuto?

- Uno studente trattenuto vale circa **3.200 €** per l'Ateneo, sia ad ottobre che a febbraio.
- A febbraio la prima rata è già incassata, ma si "risparmia" mezzo anno di costi.
- Valori medi della contribuzione ponderati sulle fasce ISEE degli studenti.

Componente	Ottobre	Febbraio
Tasse recuperate	2.872 €	2.654 €
FFO recuperato	1.818 €	1.818 €
Costi marginali (≈ 450 € l'anno)	–1.490 €	–1.265 €
Valore V	**3.201 €**	**3.207 €**
Soglia t*	**0,31**	**0,31**

Orizzonte: 1°–3° anno più 1° fuori corso (pesato al 31%).
Tasse: Guida contribuzione UniBG 2026/27. Costi marginali: bilancio UniBG 2025. Valori medi ponderati sulle fasce ISEE: bassa 45%, media 24%, alta 31%.

Pay-Off | La matrice

Ottobre (early)

	Previsto dropout (segnalato)	Previsto non dropout
Dropout reale	**a • (3.201 • e – c)**	0
Non dropout reale	**– c • a**	0

Febbraio (mid)

	Previsto dropout (segnalato)	Previsto non dropout
Dropout reale	**a • (3.207 • e – c)**	0
Non dropout reale	**– c • a**	0

Payoff per studente (€): a = adesione dei contattati, e = efficacia del servizio, V = valore di uno studente trattenuto (media ponderata sulle fasce ISEE), c = costo per aderente. Forma generale: vero positivo a • (e • V – c), falso positivo – a • c. Soglia di intervento t* = c / (e • V).

Applicazioni | Quando conviene intervenire?

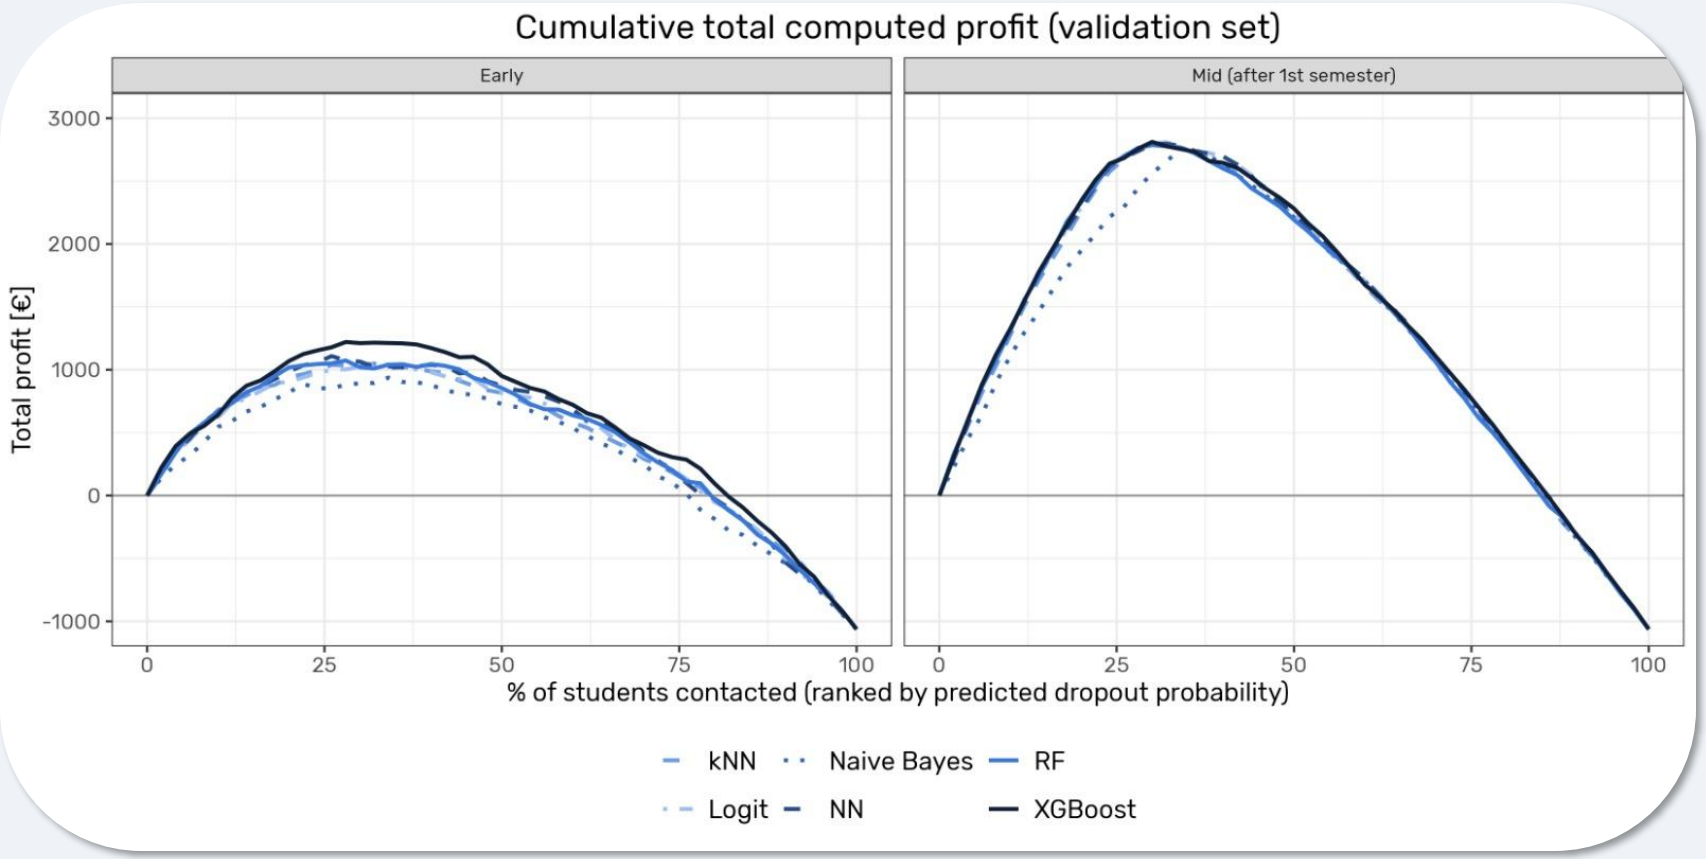
1. Il modello stima **p** per ogni matricola → 2. Chi supera la soglia **t*** viene contattato e invitato ai servizi di supporto → 3. Chi aderisce con prob. **a** costa **c**; con prob. **e** resta e l'Ateneo recupera **V**

Conviene intervenire se: $a \cdot (p \cdot e \cdot V) > a \cdot c$

$$t^* = c / (e \cdot V) = 98\,€ / (10\% \cdot 3.200\,€) \approx 0{,}31$$

Parametro	Valore	Da dove viene
c – costo per studente che aderisce	98€	Costi variabili del servizio SPEED: 3 h di tutorato + gestione
e – efficacia del servizio	10%	Letteratura sul coaching (6–12%)
a – adesione dei contattati	**≈ 2%**	**UniBG: circa 25 aderenti su 1.300 contattati nel 2025/2026**
V – valore di uno studente trattenuto	≈ 3.200 €	Tasse + FFO – costi marginali
F – costo fisso annuo	14.700 €	Cooperativa + personale d'ufficio

Applicazioni | Quando conviene intervenire?



Modello | Data la soglia

Febbraio: riconosce 3 dropout su 4; 6 segnalati su 10 sono dropout veri.

Ottobre: riconosce poco più di metà dei dropout; 4,5 segnalati su 10 sono dropout veri.

Soglia bassa: perdere un dropout può costare circa 3.200 €, un invito in più al massimo 98 €.

Campione di test: 2.132 studenti

Ottobre	Previsto dropout	Previsto non dropout
Dropout reale	307	250
Non dropout reale	374	1.201

Febbraio	Previsto dropout	Previsto non dropout
Dropout reale	422	135
Non dropout reale	279	1.296

Metrica	Ottobre	Febbraio
Sensibilità	**55%**	**76%**
Specificità	76%	82%
Precisione	**45%**	**60%**
Accuracy	71%*	81%
F1	0,50	0,67
AUC	0,72	0,86

* A ottobre l'accuracy (71%) è sotto il 74% che si otterrebbe dicendo sempre "non dropout": contano sensibilità e precisione.
Modello XGBoost M1; campione di test mai usato nella stima; quota di dropout 26%.

Modello | Mid e Early prediction

Con la soglia 0,31 si segnala circa **un terzo** delle matricole in entrambi i momenti;
a febbraio tra i segnalati ci sono molti più dropout veri: **76% intercettati contro 55%**.

Coorte di 4.500 matricole	Ottobre	Febbraio
Studenti segnalati	32% (≈ 1.440)	33% (≈ 1.480)
Dropout tra i segnalati (precisione)	45%	60%
Aderenti ai servizi (2%)	29	30
Studenti trattenuti	1,3	1,8
Profitto atteso	**1.331 €**	**2.813 €**
Profitto – costo fisso	–13.369 €	–11.887 €
Adesione necessaria per coprire il costo fisso	**22%**	**10,5%**

Profitto atteso per coorte
2.813 € a febbraio, 1.331 € a ottobre

↓

Con l'adesione attuale (2%) il **costo fisso di 14.700 €** non è coperto

Con soglie differenziate per fascia ISEE il profitto di febbraio salirebbe a circa 4.800 € e l'adesione necessaria scenderebbe al 6%.
Non la proponiamo come regola: escluderebbe la fascia ISEE bassa, in contrasto con il diritto allo studio.

Pay-Off | Per fasce ISEE

Fascia bassa (ISEE fino a 28.000 €)

	Ottobre		Febbraio	
Soglia	0,50	1,17	0,50	0,92
Segnalati	7%	0%	23%	0%
Dropout	15%	0%	60%	0%
Aderenti (a = 2%)	2,8	0,0	9,5	0,0
Studenti trattenuti	0,1	0,0	0,6	0,0
Profitto atteso	**- 160 €**	**0 €**	**- 340 €**	**0 €**

Fascia media (ISEE 28.000-58.000 €)

	Ottobre		Febbraio	
Soglia	0,50	0,29	0,50	0,30
Segnalati	4%	32%	14%	21%
Dropout	12%	64%	49%	68%
Aderenti (a = 2%)	0,9	6,9	3,0	4,6
Studenti trattenuti	0,0	0,2	0,2	0,3
Profitto atteso	**70 €**	**160 €**	**310 €**	**390 €**

Fascia alta (ISEE oltre 58.000 € o senza ISEE)

	Ottobre		Febbraio	
Soglia	0,50	0,15	0,50	0,15
Segnalati	10%	79%	38%	52%
Dropout	19%	93%	76%	88%
Aderenti (a = 2%)	2,7	21,8	10,5	14,4
Studenti trattenuti	0,2	1,0	0,8	0,9
Profitto atteso	**1.050 €**	**4.180 €**	**4.000 €**	**4.410 €**

Totale delle tre fasce e confronto con il costo fisso

	Ottobre		Febbraio	
Soglia	0,50	per fascia	0,50	per fascia
Segnalati	7%	32%	26%	21%
Dropout	16%	52%	65%	50%
Aderenti (a = 2%)	6,5	28,7	23,0	19,0
Studenti trattenuti	0,4	1,2	1,5	1,2
Profitto atteso	**960 €**	**4.340 €**	**3.960 €**	**4.800 €**
Profitto atteso	**- 13.740 €**	**- 10.360 €**	**- 10.740 €**	**- 9.900 €**
Breakeven	30,7%	6,8%	7,4%	6,1%

Sviluppi futuri | Messaggi chiave e limiti

Messaggi chiave

1. **Febbraio è il momento giusto:** AUC 0,86 contro 0,72, e rende il doppio.
2. **Soglia 0,31, non 0,5:** conviene contattare anche chi ha un rischio medio/basso.
3. **La leva è l'adesione:** dal 2% attuale al 10–11% il servizio si ripaga; con un contatto personale (tutor assegnato, invito nominativo) gli studi indicano il 25–60%.
4. **Il modello decide a chi offrire aiuto, mai chi escludere:** la fascia ISEE bassa resta inclusa.

Limiti

Covariate mancanti: titolo di studio dei genitori, condizione lavorativa dello studente.

Covariate tardive: la fascia ISEE è disponibile a dicembre (a ottobre è un what-if).

Un dropout su quattro non è intercettabile: esami superati, abbandono nel 2° semestre o trasferimento.

Efficacia del 10%: dalla letteratura americana, è l'ipotesi più incerta; in Italia non ci sono studi simili.

Bias a favore del "mid term": diversi dropout avvengono già prima della prima sessione.

Li et al. (2026): lo stesso modello ordina bene gli studenti in tutti i corsi, ma va ricalibrato corso per corso.

Bibliografia e fonti

Previsione del dropout:

- Li, X., Segato, F., Abbiati, G., Origo, F., Manzella, E. (2026). *Same Problem, Different Causes: Heterogeneity in the Predictors of First-Year University Dropout.* Manoscritto inedito, progetto SPEED.
- Cannistrà, M., Masci, C., Ieva, F., Paganoni, A. M., Agasisti, T. (2022). *Early-predicting dropout of university students. Studies in Higher Education, 47(9), 1935–1956.*

Efficacia e adesione degli interventi:

- Bettinger, E. P., Baker, R. B. (2014). *The Effects of Student Coaching.* Educational Evaluation and Policy Analysis, 36(1), 3–19.
- Angrist, J., Lang, D., Oreopoulos, P. (2009). *Incentives and Services for College Achievement.* American Economic Journal: Applied Economics, 1(1), 136–163.
- Robinson, C. D., Bisht, B., Loeb, S. (2022). *The inequity of opt-in educational resources.* EdWorkingPaper 22-654.

Contesto e dati economici:

- ANVUR (2026). *Rapporto sul sistema della formazione superiore e della ricerca.*
- MUR (2025). *Riparto FFO 2025*, DM 595/2025.
- Università di Bergamo: *Guida alla contribuzione 2025/26; Bilancio di esercizio 2025;* dati degli uffici SPEED.

https://github.com/SavarDar2204/Dropout-UniBG

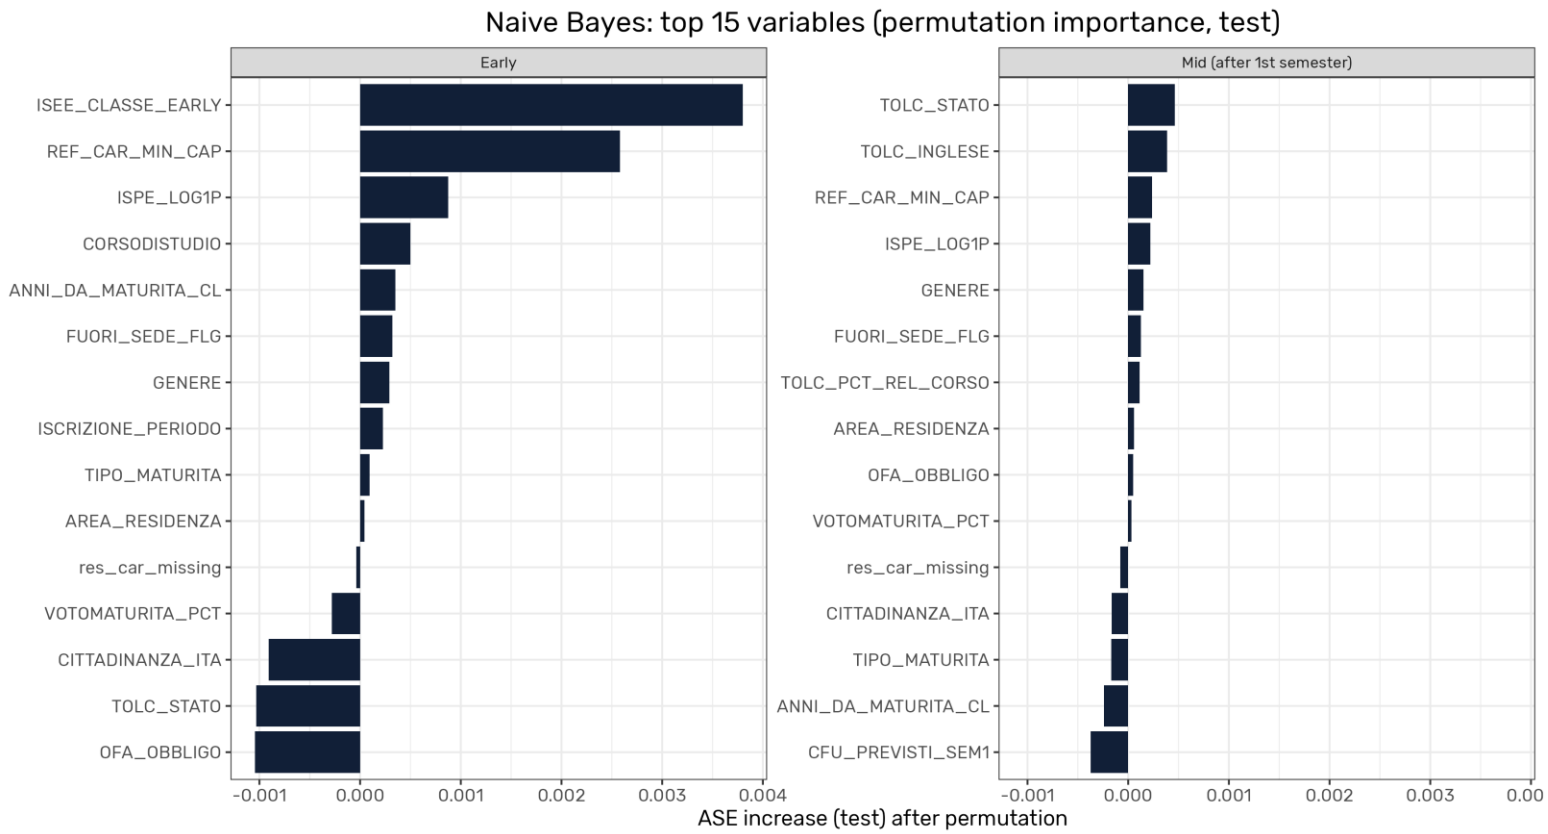
UNIVERSITÀ
DEGLI STUDI
DI BERGAMO

Grazie per l’attenzione!

Naive Bayes

- Applicazione del Teorema di Bayes sotto ipotesi di indipendenza delle covariate.
- Eliminazione delle variabili molto correlate tra di loro e discretizzazione in classi delle variabili continue.
- Nessun iperparametro per gestire la complessità del modello.

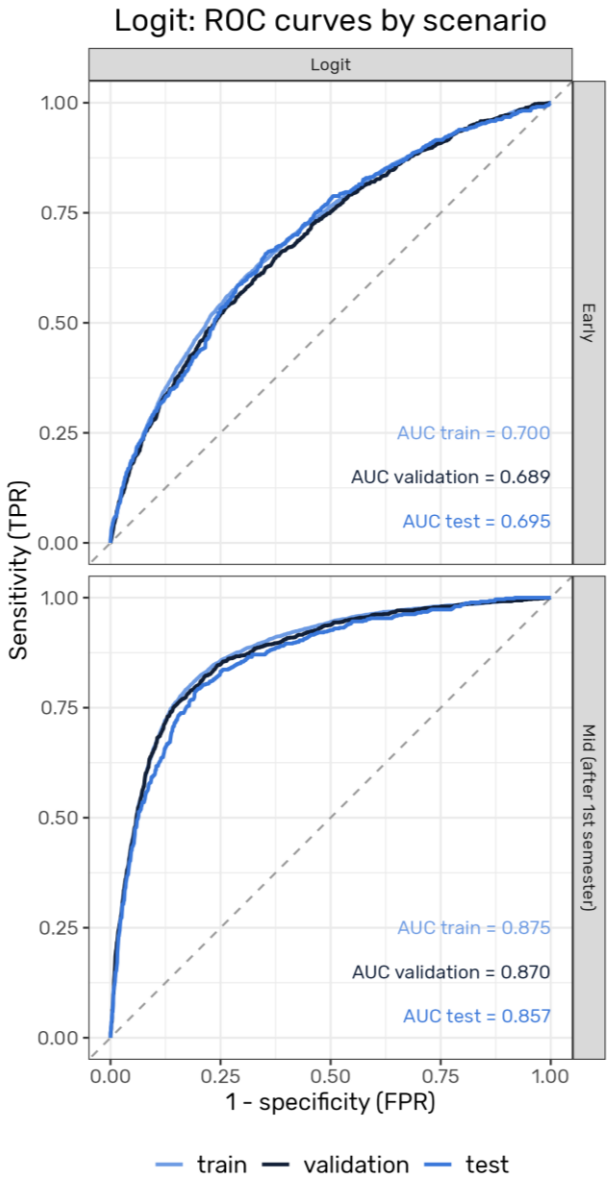
	ASE	AUC
Early	0,197	0,670
Mid	0,184	0,851



Logistic Regression

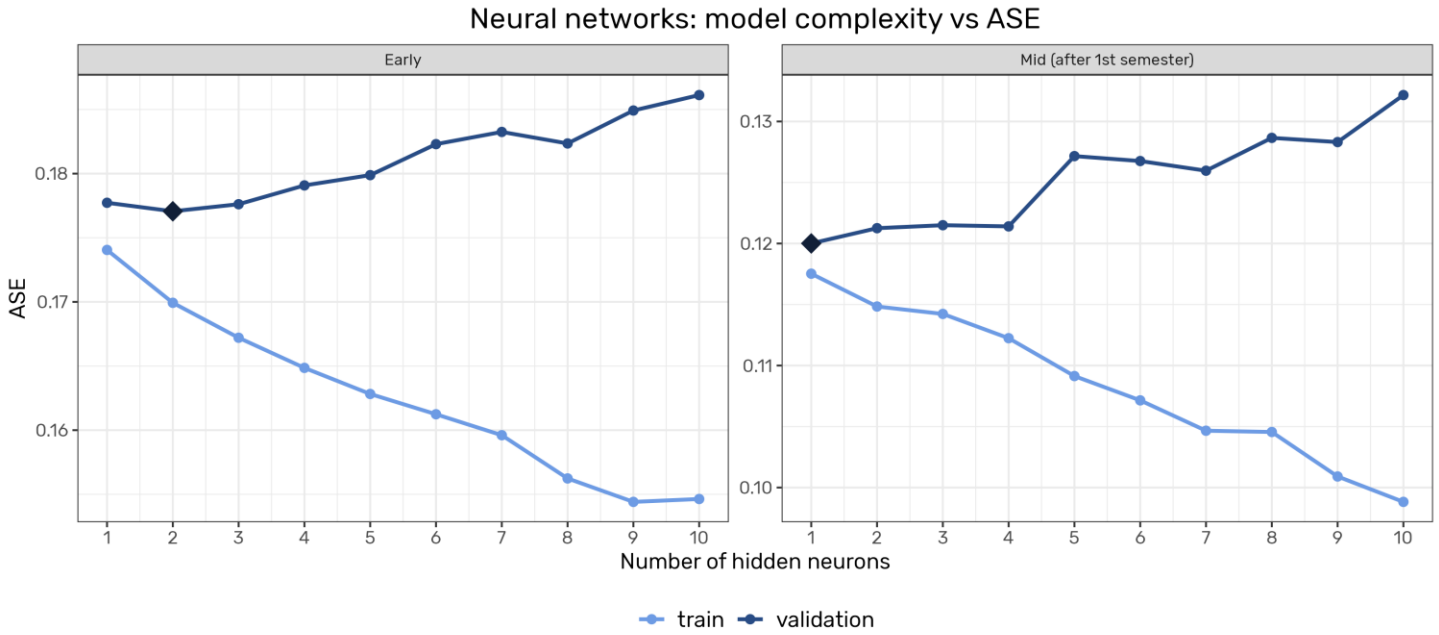
- Regressione logistica, aggiungendo un blocco di variabili alla volta (scelta migliore: tutte le variabili).
- Nel caso lineare, i coefficienti associati ad ogni covariata si leggono come contributo al log-odds.
- Penalizzazione dei coefficienti con *elastic net* e aumento di grado dei coefficienti non hanno effetto su ASE e AUC.
- Nello scenario Mid, le performance sono comparabili con XGBoost.

	ASE	AUC
Early	0,178	0,689
Mid	0,120	0,870



Reti Neurali

- Un solo hidden layer, con funzioni di attivazione logistiche.
- Basso numero di neuroni (nel Mid addirittura un solo neurone): l'effetto della non linearità scelta è molto basso.
- Loss function: SSE + regolarizzazione L2.



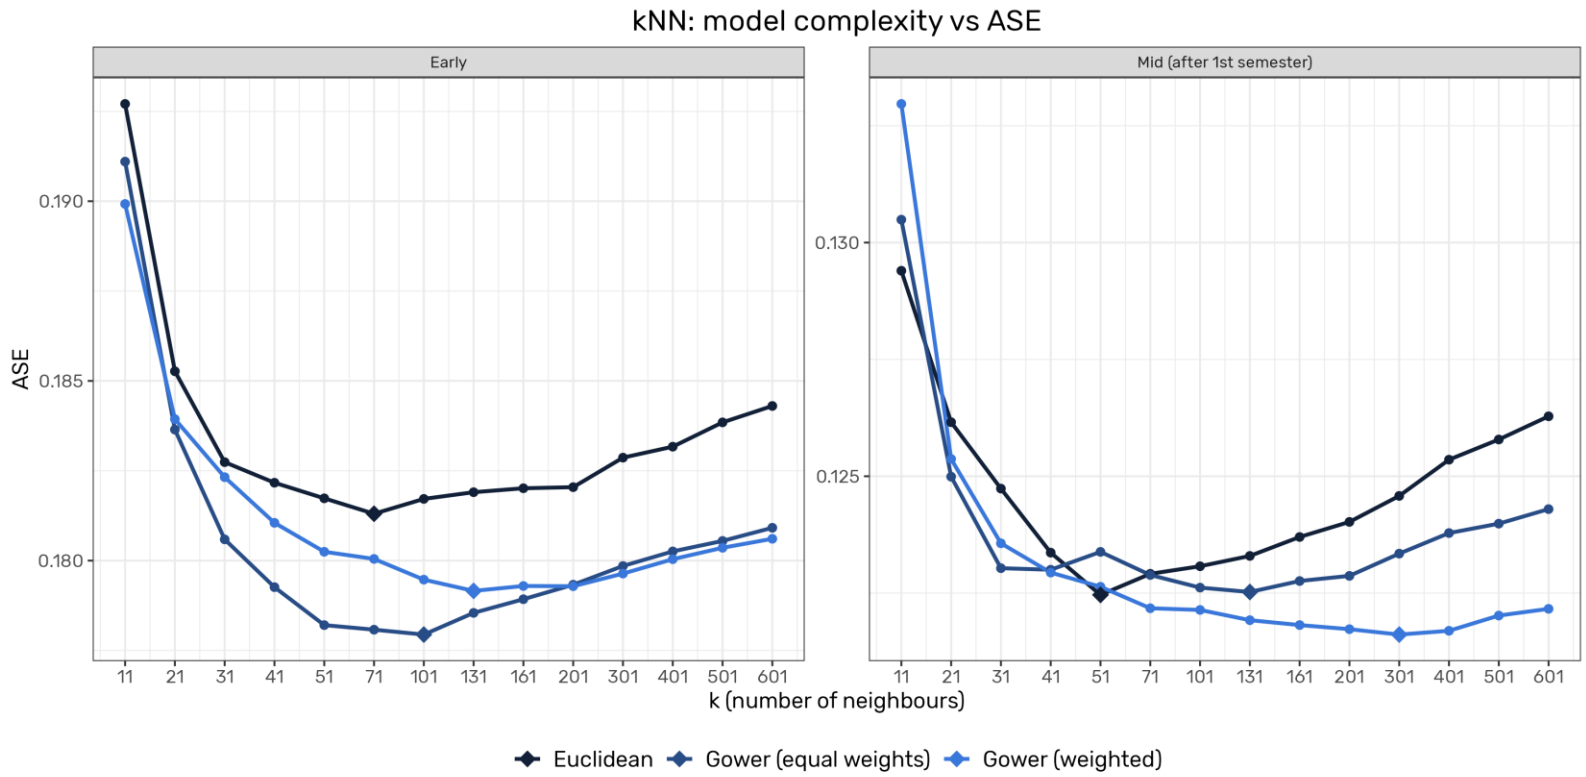
	ASE	AUC
Early	0,177	0,694
Mid	0,120	0,870

k-Nearest Neighbors

- Ad ogni studente è assegnata la quota di dropout tra i *k* studenti più vicini.

- Tre distanze:
  - Euclidea.
  - Gower (le distanze delle variabili numeriche sono mappate in [0; 1] per poterle confrontare direttamente con le categoriche).
  - Gower pesato (le variabili più importanti pesano di più).

	ASE	AUC
Early	0,178	0,689
Mid	0,122	0,866



Random Forest

- 500 alberi su campioni bootstrap. Due iper parametri: *nodesize* e *mtry.*
- Indice di Gini per split tra i diversi nodi.
- Interpretazione delle variabili più importanti. Ad esempio: nello scenario Early le variabili più importanti sono il corso di studio scelto e il tempo di viaggio nel tragitto casa-università.

	ASE	AUC
Early	0,177	0,693
Mid	0,121	0,866

